


# BART: Bayesian Additive Regression Trees

Luis D. Suárez

Estimación Bayesiana, Noviembre 2024



# Modelo de Árbol



- Soluciones algorítmicas “*greedy*”.
- Requiere *prunning*.
- Ensembles o boosting para mejorar performance.

$$\begin{aligned}y = & \mu_1 I_{\{x_3 < 100\}} + \mu_2 I_{\{x_3 \geq 100\}} I_{\{x_1 \leq 13\}} \\ & + \mu_3 I_{\{x_3 \geq 100\}} I_{\{x_1 > 13\}} I_{\{x_5 > 0,4\}} \\ & + \mu_4 I_{\{x_3 \geq 100\}} I_{\{x_1 > 13\}} I_{\{x_5 \leq 0,4\}} + \varepsilon\end{aligned}$$

# Suma de árboles



$$Y = \sum_{j=1}^m g_j(x) + \varepsilon$$

$$\begin{aligned} y = & \mu_{11} I_{\{x_3 < 100\}} + \mu_{12} I_{\{x_3 \geq 100\}} I_{\{x_1 \leq 13\}} + \mu_{13} I_{\{x_3 \geq 100\}} I_{\{x_1 > 13\}} I_{\{x_5 > 0,4\}} \\ & + \mu_{14} I_{\{x_3 \geq 100\}} I_{\{x_1 > 13\}} I_{\{x_5 \leq 0,4\}} \\ & + \mu_{21} I_{\{x_5 \leq 20\}} + \mu_{22} I_{\{x_5 > 20\}} I_{\{x_3 \leq 22\}} + \mu_{23} I_{\{x_5 > 20\}} I_{\{x_3 > 22\}} I_{\{x_4 < 66\}} \\ & + \mu_{24} I_{\{x_5 > 20\}} I_{\{x_3 > 22\}} I_{\{x_4 \geq 66\}} + \varepsilon \end{aligned}$$

# BART: un modelo bayesiano de suma de árboles

Modelo de árboles aditivos:

$$Y = \sum_{j=1}^m g(x; \mathcal{T}_j, \mathcal{M}_j) + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2).$$

Prior:

$$p\left((\mathcal{T}_1, \mathcal{M}_1), \dots, (\mathcal{T}_m, \mathcal{M}_m), \sigma\right)$$

Se propone utilizar un priores bajo el supuesto de independencia de cada  $(\mathcal{T}_j, \mathcal{M}_j)$  entre sí y con respecto a  $\sigma$ . Es decir que

$$\text{Prior} = \left[ \prod_j p(\mathcal{M}_j \mid \mathcal{T}_j, ) p(\mathcal{T}_j) \right] p(\sigma), \quad \text{con } p(\mathcal{M}_j \mid \mathcal{T}_j, ) = \prod_i^{b_j} p(\mu_{ij} \mid \mathcal{T}_j)$$

# Especificación de los priores de BART

- $\mathcal{T}_j$  está especificado por tres aspectos:
  - La probabilidad de que un nodo a profundidad  $d$  sea no-terminal.
  - La distribución de las variables de división.
  - La distribución de los valores de división.

# Especificación de los priores de BART

- $\mathcal{T}_j$  está especificado por tres aspectos:
  - La probabilidad de que un nodo a profundidad  $d$  sea no-terminal.
  - La distribución de las variables de división.
  - La distribución de los valores de división.
- $p(\mu_{ij} \mid \mathcal{T}_j)$ 

Se puede utilizar un prior conjugado Normal.

Si se reescala el target, e.g.  $(-0.5, 0.5)$ , se puede simplificar a

$$\mu_{ij} \sim \mathcal{N}(0, \sigma_{\mu}^2)$$

# Especificación de los priores de BART

- $\mathcal{T}_j$  está especificado por tres aspectos:
  - La probabilidad de que un nodo a profundidad  $d$  sea no-terminal.
  - La distribución de las variables de división.
  - La distribución de los valores de división.
- $p(\mu_{ij} | \mathcal{T}_j)$   
Se puede utilizar un prior conjugado Normal.  
Si se reescala el target, e.g.  $(-0.5, 0.5)$ , se puede simplificar a

$$\mu_{ij} \sim \mathcal{N}(0, \sigma_\mu^2)$$

- $\sigma$   
Un prior conjugado Gamma inversa (típicamente  $\chi^2$  inversa).

$$\sigma \sim \nu\lambda/\chi_\nu^2$$

# Especificación de los priores de BART

- $\mathcal{T}_j$  está especificado por tres aspectos:
  - La probabilidad de que un nodo a profundidad  $d$  sea no-terminal.
  - La distribución de las variables de división.
  - La distribución de los valores de división.
- $p(\mu_{ij} \mid \mathcal{T}_j)$   
Se puede utilizar un prior conjugado Normal.  
Si se reescala el target, e.g.  $(-0.5, 0.5)$ , se puede simplificar a

$$\mu_{ij} \sim \mathcal{N}(0, \sigma_{\mu}^2)$$

- $\sigma$   
Un prior conjugado Gamma inversa (típicamente  $\chi^2$  inversa).

$$\sigma \sim \nu\lambda/\chi_{\nu}^2$$

- $m$



## Bayesian Backfitting MCMC

- ▶ Objetivo: extraer  $m$  muestras de  $(\mathcal{T}_j, \mathcal{M}_j) \mid \mathcal{T}_{(j)}, \mathcal{M}_{(j)}, \sigma, y$

$$R_j \equiv y - \sum_{k \neq j} g(x; \mathcal{T}_k, \mathcal{M}_k)$$

El problema se reduce a obtener un árbol por vez usando  $R_j$  en lugar de  $y$ .

# Muestreo del posterior

## Bayesian Backfitting MCMC

- ▶ Objetivo: extraer  $m$  muestras de  $(\mathcal{T}_j, \mathcal{M}_j) \mid \mathcal{T}_{(j)}, \mathcal{M}_{(j)}, \sigma, y$

$$R_j \equiv y - \sum_{k \neq j} g(x; \mathcal{T}_k, \mathcal{M}_k)$$

El problema se reduce a obtener un árbol por vez usando  $R_j$  en lugar de  $y$ .

- ▶ Generar un nuevo árbol  $\mathcal{T}_j^*$  a partir de un set de reglas:  
Grow      Prune      Swap      Change

## Bayesian Backfitting MCMC

- ▶ Objetivo: extraer  $m$  muestras de  $(\mathcal{T}_j, \mathcal{M}_j) \mid \mathcal{T}_{(j)}, \mathcal{M}_{(j)}, \sigma, y$

$$R_j \equiv y - \sum_{k \neq j} g(x; \mathcal{T}_k, \mathcal{M}_k)$$

El problema se reduce a obtener un árbol por vez usando  $R_j$  en lugar de  $y$ .

- ▶ Generar un nuevo árbol  $\mathcal{T}_j^*$  a partir de un set de reglas:  
Grow      Prune      Swap      Change

- ▶ Metropolis-Hastings para seleccionar entre  $\mathcal{T}_j$  y  $\mathcal{T}_j^*$

# Conclusión

- BART puede capturar interacciones complejas entre variables predictivas.
- Tiene pocos hiperparámetros que pueden fácilmente determinarse con valores default.
- Puede ser extendido fácilmente (e.g. para clasificación).
- El outcome es un *posterior de sumas de árboles*:
  - Predicciones con intervalos de credibilidad.
  - Produce medidas directas para *Feature Selection*.

¡Muchas Gracias!

... preguntas?